

Detection de Fraude par Carte Bancaire

Rapport d'analyse — Projet Data Science

Dataset : ULB / Worldline · Credit Card Fraud Detection · Kaggle
Mai 2026

Dr Namory FOFANA

284 807 transactions	0,172 % de fraudes	AUPRC 0,755	Cout optimal : 2 307 EUR
Dataset complet	Desequilibre extreme	Modele final	vs 58 591 EUR (inaction)

1. Resume Executif

Ce projet developpe un systeme de detection de fraude par carte bancaire sur le dataset ULB/Worldline (284 807 transactions europeennes, septembre 2013). Le defi principal est le desequilibre extreme : 492 fraudes pour 284 315 transactions legitimes (0,172 %). La metrique principale retenue est l'AUPRC (aire sous la courbe Precision-Rappel), recommandee par les auteurs du dataset.

Le modele final est un LightGBM tune par Optuna (50 trials) atteignant une AUPRC de 0,755 sur le test set temporel, avec un cout optimal de 2 307 EUR — soit 56 284 EUR economies par rapport a l'inaction (58 591 EUR de fraudes dans le dataset).

Indicateur	Valeur	Signification
AUPRC (test)	0,755	Capacite de ranking fraude vs legitime
Cout optimal	2 307 EUR	FN + FP au seuil optimal (0,281)
Rappel	77,3 %	75 fraudes sur 97 detectees
Precision	38,3 %	3 alertes sur 8 sont de vraies fraudes
Detection@80%	372 alertes (0,51 %)	Pour capturer 80 % des fraudes
Brier score	0,0009	Probabilites tres bien calibrees
Stabilite (std)	+/- 0,013	Sur 5 seeds differents

Limite principale : 89 % du signal provient de composantes PCA anonymisees (V1-V28). Sans ces features, l'AUPRC tombe a 0,002. Le modele ne peut pas s'expliquer en termes metier — point critique pour la conformite RGPD.

2. Donnees et Methodologie

2.1 Description du dataset

Le dataset contient des transactions par carte bancaire de septembre 2013 sur 2 jours consecutifs. Les features V1-V28 sont des composantes PCA pour des raisons de confidentialite. Seuls Time (secondes depuis la 1ere transaction) et Amount (montant en EUR) sont bruts.

Caracteristique	Valeur
Transactions totales	284 807
Fraudes (brut)	492 (0,172 %)
Doublons supprimes	1 081 (dont 19 fraudes)
Apres nettoyage	283 726 · 473 fraudes (0,167 %)
Ratio legitime/fraude	1 fraude / 598 legitimes
Montant total fraude	58 591,39 EUR
Montant median fraude	9,82 EUR (median legitime : 22,00 EUR)
Periode couverte	48 heures — septembre 2013 — Europe




Fig. 1 — Desequilibrium des classes et distribution des montants fraudes

2.2 Pipeline methodologique (12 phases)

Phase	Action	Decision cle
1 — EDA	Exploration	1 081 doublons · 0 valeur manquante
2 — Cout	Matrice FN/FP	FN = Amount · FP = 5 EUR fixe
3 — Split	Split temporel 80/20	Train 38,4h · Test 9,6h · Overlap = 0
4 — Features	Engineering Time/Amount	35 features · is_night d=0,61
5 — Resampling	5 strategies comparees	SMOTETomek retenu (AUPRC 0,797 sur LR)
6 — Baseline	LR + IF + LGB	LR baseline : AUPRC 0,7845
7 — Avance	Optuna 50 trials LGB	LGB Optuna : AUPRC 0,755 · cout 2 307 EUR
8 — Hybride	Autoencoder + Stacking	Aucun gain vs Phase 7
9 — Eval finale	Test set isole	LGB Optuna retenu (4 criteres / 6)
10 — SHAP	Interpretabilite	V14 driver principal · 89% non-actionnable
11 — Audit	Robustesse	Rappel 10-50 EUR : 54,5% · Drift -0,106
12 — Monitoring	KS + PSI + AUPRC glissant	Chute AUPRC 0,48 apres 46h

3. Modelisation

3.1 Feature Engineering (35 features)

35 features finales : 28 composantes PCA (V1-V28), $\log_{10}(\text{Amount})$ apres RobustScaler, et 6 features derivees de Time. Le critere de selection est Cohen's d $\geq 0,3$.




Fig. 2 — Cohen's d des features candidates. Les V^* (hors echelle, $V17\ d=9,12$) dominant le signal.

3.2 Comparaison des modeles

Modele	AUPRC	Rappel	Precision	Cout opt. (EUR)
LR baseline (P6)	0,741	0,814	0,437	2 927
LGB + ISO feature (P7)	0,771	0,732	0,960	2 931
LGB SMOTETomek (P7)	0,766	0,825	0,245	2 663
LGB Optuna tuned (P7) [RETENU]	0,755	0,773	0,383	2 307
Stacking P8	0,735	—	—	2 565
Isolation Forest	0,041	0,557	0,051	8 090




Fig. 3 — AUPRC et cout optimal par modele (vert = modele retenu)

Modele retenu : LGB Optuna tuned — meilleur cout (2 307 EUR), meilleure calibration (Brier 0,0009), plus stable (std +/- 0,013 sur 5 seeds).

4. Evaluation Finale

4.1 Metriques comparees sur le test set

Critere	LR baseline	LGB Optuna	Gagnant
AUPRC	0,741	0,755	LGB
AUC-ROC	0,9795	0,9082	LR (indicatif)
Brier score	0,0472	0,0009	LGB (calibration)
Rappel	0,814	0,773	LR (+4 fraudes)
Precision	0,437	0,383	LR
Cout optimal	2 927 EUR	2 307 EUR	LGB (-620 EUR)
% montant recupere	15,7 %	16,9 %	LGB
Detection@80%	167 tx (0,23%)	372 tx (0,51%)	LR (moins alertes)
Stabilite std	+/- 0,027	+/- 0,013	LGB (2x plus stable)
TP / FN / FP	79 / 18 / 102	75 / 22 / 121	—




Fig. 4 — Gauche : courbe cout vs seuil. Droite : lift curve (Detection@k)

4.2 Structure de cout retenue

Le faux negatif (fraude non detectee) coute le montant de la transaction fraudee. Le faux positif (transaction legitime bloquee) coute 5 EUR fixe. Le scenario aleatoire (bloquer 50 % au hasard) couterait 742 827 EUR — 12x le cout de l'inaction.

Brier score LGB = 0,0009 : les probabilites sont directement exploitables comme scores de risque dans l'application. LR (0,0472) necessiterait une calibration Platt.

5. Interpretabilite — SHAP

L'interpretabilite est limitee par la nature anonymisee des features V*. SHAP indique leur poids mais pas leur signification metier. Seuls Amount et les features temporelles sont directement interpretables.




Fig. 5 — Gauche : importance SHAP (rouge = interpretable). Droite : 89 % du signal est non-actionnable.

Feature	SHAP moyen	Type	Interpretation
V14	0,597	PCA anonyme	Driver principal (90%+ des decisions)
V11	0,540	PCA anonyme	PSI=0,31 — instable en production
hour_sin	0,432	Interpretable	Fraudes concentrees la nuit (2h)
Amount_log1p	0,274	Interpretable	Gros montants = score plus eleve
is_night	0,000	Interpretable	Redondant avec hour_sin/cos

Message cle : les alertes portees par un fort SHAP V14 sont les plus fiables. Les alertes dont le 2e driver est Amount_log1p correspondent souvent a des faux positifs.

6. Audit de Robustesse

Cet audit teste les angles morts sur 4 axes : tranches de montant, creneaux horaires, drift temporel, et dependance aux features anonymes.




Fig. 6 — Rappel et % montant recupere par tranche. La tranche 10-50 EUR est l'angle mort critique (54,5%).

Priorite	Finding	Valeur	Action requise
HAUTE	Rappel fraudes 10-50 EUR	54,5 %	Analyser FN, ajuster seuil
HAUTE	Drift intra-test	AUPRC -0,106 en 5h	Monitoring obligatoire
HAUTE	Dependance aux V*	AUPRC sans V* = 0,002	Documenter pour RGPD
HAUTE	Representativite	2 jours · Europe · 2013	Valider avant prod
MOYENNE	Rappel soiree (14-22h)	50-67 %	Investiguer fraudes de soiree

7. Monitoring et Drift

Le monitoring est critique : un drift de -0,106 AUPRC a été mesuré en seulement 5 heures de données supplémentaires. La chute se produit de façon brutale après 45h.




Fig. 7 — AUPRC fenetre glissante : stable jusqu'a 45h, puis effondrement a 0,48 en 2h.

Signal	Valeur	Seuil alerte	Statut
Features KS driftees (p<0.05)	30 / 30	>= 5	ALERTE
Features PSI > 0,25	4 (V1,V3,V28,V11)	>= 1	ALERTE
PSI score distribution	0,0915	> 0,10	STABLE (limite)
KS score distribution	0,137	> 0,05	MODERE
Chute AUPRC max	0,755 -> 0,482 (-0,273)	> 0,10	RETRAINING

7.2 Regles de retraining

Signal	Alerte	Retraining	Frequence
AUPRC (fenetre glissante)	< 0,70	< 0,65	Quotidienne
PSI score de fraude	> 0,10	> 0,25	Hebdomadaire
KS features driftees	>= 5 features	>= 10 features	Hebdomadaire
PSI V11 specifique	> 0,40	> 0,50	Hebdomadaire

Verdict actuel : RETRAINING NECESSAIRE — chute AUPRC de -0,273 depasse le seuil. V11 (driver SHAP #2, PSI=0,31) est l'indicateur avance le plus fiable.

8. Conclusions et Recommandations

8.1 Synthèse des résultats

Modele Final	Points Forts	Limites et Next Steps
LGB Optuna tuned	Cout 620 EUR < LR baseline	RGPD : 89% non-explicable
AUPRC : 0,755	Brier score : 0,0009	Rappel 10-50 EUR : 54,5%
Cout opt. : 2 307 EUR	Stable (std 2x < LR)	Drift rapide (5h)
Seuil : 0,281	V14 stable en production	Dataset : 2j · 2013
Brier : 0,0009	Detection@80% : 372 tx	Valider avant production

8.2 Plan d'action

Priorite	Action	Impact attendu
Court terme	Deployer LGB Optuna (seuil 0,281) + monitoring quotidien AUPRC	Economie ~56 284 EUR/periode
Court terme	Analyser manuellement les 22 FN (fraudes manquées 10-50 EUR)	Ameliorer rappel tranche critique
Moyen terme	Retraining mensuel + fenetre glissante AUPRC quotidienne	Prevenir degradation apres 45h
Moyen terme	Documenter droit à l'explication (Art. 22 RGPD)	Conformite reglementaire
Long terme	Acquérir données récentes + multi-géographies	Dataset actuel : 2j · 2013

Section Honesty

Les hyperparamètres Optuna ont été tunes sur un val set de 75 fraudes seulement (risque de surapprentissage au val set). Le modèle a été entraîné et évalué sur 2 jours — la généralisation à d'autres périodes et géographies n'est pas garantie. Les probabilités LGB sont bien calibrées (Brier 0,0009) mais le seuil optimal (0,281) doit être revalidé en production avec les vrais coûts FP. Le code LightGBM ne s'est arrêté qu'à 2 itérations quand le test set était utilisé pour l'early stopping (Phase 6) — corrige en Phase 7 avec un val set dédié.